Dokuz Eylül Üniversitesi

Fen Fakültesi / Bilgisayar Bilimleri Bölümü

2025-2026 BAHAR DÖNEMİ

BİL 4112 Yapay Zeka Dersi

Dersin Öğretim Üyesi: ……

PROJE RAPORU

Akıllı Tarım: İklim ve Toprak Sensörü Verileriyle XGBoost ve Random Forest Tabanlı Hasat Kalitesi Tahmini

Hazırlayanlar:

Öğrenci No - Ad Soyad: …… - Eren ÖNDER

Öğrenci No - Ad Soyad: …… - Harun YARDIMCI

Öğrenci No - Ad Soyad: …… - Oğulcan TEKİNEŞ

Öğrenci No - Ad Soyad: …… - Gamze KOÇAK

Teslim Tarihi: [Gün/Ay/Yıl]

Özet

Bu çalışmanın temel amacı, tarımsal üretimde elde edilecek rekolte kalitesini çevresel faktörlere dayanarak önceden tahmin edebilen, yüksek doğruluklu ve makine öğrenmesi destekli bir karar destek sistemi geliştirmektir. Günümüzde hızla artan dünya nüfusu, derinleşen iklim değişikliği krizleri, düzensiz yağış rejimleri ve tarım topraklarının hatalı gübreleme sonucu tuzlanarak verimsizleşmesi gibi küresel krizler, tarımsal verimliliği en üst düzeye çıkarmayı ve gıda güvenliğini sağlamayı zorunlu kılmaktadır. Çalışmada, Türkiye'nin tarımsal ihracat ve üretim kapasitesi açısından en önemli havzalarından biri olan İzmir iline ait 16 yıllık (2006-2023) geçmişe dayanan meteorolojik iklim verileri (Open-Meteo REST API aracılığıyla çekilen sıcaklık, yağış ve güneşlenme verileri) ile tarımsal kimyayı simüle eden sentetik toprak sensörü verileri (Azot, Fosfor, Potasyum, Toprak Nemi, pH) birleştirilerek, veri mühendisliği teknikleriyle 6000 günlük hibrit bir "dijital ikiz" (Digital Twin) veri seti oluşturulmuştur.

Meydana getirilen yapısal (tabular) veri seti üzerinde, makine öğrenmesi literatüründe geleneksel derin öğrenme modellerinden çok daha üstün performans gösterdikleri kanıtlanmış olan ağaç tabanlı algoritmalar, spesifik olarak Random Forest (Rassal Orman) ve XGBoost (Extreme Gradient Boosting) algoritmaları eğitilmiş ve bu modellerin öğrenme başarıları çok boyutlu metriklerle karşılaştırmalı olarak analiz edilmiştir. Modellerin ezberlemesini (overfitting) kesin olarak engellemek ve doğadaki öngörülemez meteorolojik/biyolojik ekstrem olayları simüle etmek adına veri setine %15 oranında kontrollü "doğa gürültüsü (noise)" entegre edilmiştir. Temel model (baseline) olarak kurgulanan Random Forest algoritması %69.92 doğruluk (accuracy) sağlarken, yapısal hatalardan ardışık olarak öğrenme yeteneğine sahip XGBoost

modeli %72.50 doğruluk skoruna ulaşarak en iyi performansı sergilemiş ve azınlık sınıflarını (A Kalite) tespit etmede öne çıkmıştır. Model, son kullanıcıların (çiftçiler ve ziraat mühendisleri) pratik bir şekilde faydalanabilmesi için Streamlit framework'ü tabanlı, tamamen etkileşimli bir web arayüzüne dönüştürülmüş ve tarımsal otomasyona entegrasyonu başarıyla sağlanmıştır.

Anahtar kelimeler: Yapay zeka, Makine Öğrenmesi, XGBoost, Random Forest, Akıllı Tarım, Tarım 4.0, Streamlit, Karar Destek Sistemleri.

1. Giriş

Tarımsal üretim, tarih boyunca insanlığın temel besin ihtiyacını karşılayan ve ekonomik kalkınmanın bel kemiğini oluşturan en kritik sektör olmasına rağmen, doğası gereği son derece yüksek belirsizlikler barındırmaktadır. Günümüzde iklim değişiklikleri (küresel ısınma kaynaklı ani sıcaklık değişimleri), kuraklık, toprak yapısındaki kimyasal bozulmalar ve düzensiz yağış rejimleri gibi pek çok dinamik ve öngörülemez değişkene bağlı olarak tarımsal üretim büyük riskler altındadır. Geleneksel tarım yöntemleri, çiftçinin önceki yıllardan edindiği tecrübesine ve sezgisel gözlemine dayanırken; modern çağda bu sübjektif yöntemler, Birleşmiş Milletler (BM) tahminlerine göre 2050 yılına kadar 10 milyarı bulacak nüfusun taleplerini karşılamada ve gübre, su gibi kısıtlı kaynakların israfını önlemede oldukça yetersiz kalmaktadır. Bu darboğazı aşmak için veri madenciliği, nesnelerin interneti (IoT) ve makine öğrenmesini kapsayan "Tarım 4.0" (Smart Agriculture / Akıllı Tarım) vizyonu hayati bir önem kazanmıştır.

Bu projenin temel vizyonu ve mühendislik hedefi, belirli bir coğrafi bölgenin çok uzun yıllara dayanan iklimsel davranış örüntüleriyle, o bölgedeki toprağın makro ve mikro kimyasal özelliklerini matematiksel düzlemde harmanlayarak, çiftçinin henüz ekim yaparken veya yetiştirme sezonundayken ürününün hasat kalitesini yüksek doğrulukla öngörebilen prediktif (öngörücü) bir yapay zekâ mimarisi kurmaktır. Seçilen bölge olan İzmir, hem Akdeniz ikliminin tüm karakteristik özelliklerini net bir şekilde yansıtması, hem de Menemen ve Torbalı gibi bereketli ovalarıyla Türkiye'nin tarımsal ihracatında kritik bir role sahip olması sebebiyle ideal bir pilot bölge olarak belirlenmiştir.

Geliştirilen bu yapay zeka sistemi sayesinde çiftçiler ve ziraat mühendisleri, hasattan aylar önce alacakları sistem uyarılarıyla topraklarındaki eksik minerali veya suyu tespit ederek gübreleme

(Özellikle Azot, Fosfor ve Potasyum yönetimi) ve sulama stratejilerini proaktif olarak optimize edebileceklerdir. Bu durum, gereksiz ve aşırı kimyasal gübre kullanımını azaltarak hem çiftçi için ciddi bir maliyet tasarrufu sağlayacak hem de yeraltı sularının kirlenmesini önleyerek çevresel sürdürülebilirliğe doğrudan katkıda bulunacaktır.

Raporun ilerleyen bölümlerinde, büyük veri (Big Data) havuzunun nasıl mühendislik işlemlerinden geçirildiği, "dijital ikiz" veri setinin oluşturulma aşamaları, sınıflandırma görevinde hangi algoritmaların (Random Forest ve XGBoost) tercih edildiği, bu algoritmaların matematiksel altyapıları, modellerin hiperparametre ayarları, karşılaştırmalı performans analizleri ve projenin canlı bir web uygulamasına nasıl entegre edildiği detaylı olarak açıklanacaktır.

2. Literatür Taraması

Son yirmi yılda yapay zekâ algoritmalarının, sensör teknolojilerinin ve bulut bilişim destekli büyük veri (Big Data) analitiğinin tarım sektörüne entegrasyonu muazzam bir ivme kazanmıştır. Literatür incelendiğinde, tarımsal ürün rekoltesi ve kalitesi tahmini üzerine yapılan çalışmalar kronolojik olarak iki ana koldan ilerlemektedir.

2.1. Geleneksel İstatistiksel Yaklaşımlar

Yapay zekanın popülerleşmesinden önceki dönemde yapılan çalışmalar genellikle Çoklu Doğrusal Regresyon (Multiple Linear Regression), Lojistik Regresyon ve zaman serisi (Time Series) analizi modellerine (ARIMA, SARIMA vb.) dayanmaktadır. Araştırmacılar, yıllık ortalama sıcaklık ve metrekareye düşen toplam yağış gibi sınırlı sayıda iklimsel değişkenin rekolte üzerindeki etkisini ölçmek için bu geleneksel yöntemleri kullanmışlardır. Bu modeller, değişkenler arasındaki doğrusal ilişkileri (lineer korelasyon) belirlemede başarılı olsalar da, tarımsal ekosistemlerin doğası gereği içerdiği son derece karmaşık, doğrusal olmayan (non-linear) ilişkileri (örneğin aşırı yağışın pH'ı değiştirerek Azot emilimini bozması gibi) ve ani iklim anormalliklerini modellemekte tamamen yetersiz kalmışlardır.

2.2. Makine Öğrenmesi ve Ağaç Tabanlı Algoritmalarla Yapılan Güncel Çalışmalar

Günümüzde modern araştırmalar, doğrusal olmayan karmaşık ilişkileri çözebilen makine

öğrenmesi algoritmalarına yönelmiştir. Derin Öğrenme (Deep Learning) mimarileri genellikle görüntü işleme tabanlı bitki hastalığı tespiti gibi alanlarda kullanılırken; iklim istasyonlarından ve toprak sensörlerinden gelen sayısal tablo (tabular data) verileri söz konusu olduğunda, ağaç tabanlı (Tree-based) algoritmaların (Random Forest, XGBoost vb.) üstünlüğü kanıtlanmıştır. Bu alanda öne çıkan literatür çalışmaları şunlardır:

- **Thomas van Klompenburg, Ayalew Kassahun ve Cagatay Catal (2020) - *Crop Yield Prediction Using Machine Learning: A Systematic Literature Review*:** Tarımsal rekolte tahmini üzerine yapılmış bağımsız makine öğrenmesi projelerini analiz eden bu geniş kapsamlı literatür taraması sonucunda; mahsul verimini tahmin etmede dünyada kullanılan en etkili girdilerin "sıcaklık, yağış ve toprak özellikleri (pH, besin vb.)" olduğu kanıtlanmıştır. Bu bulgu, projemizdeki "meteoroloji + toprak sensörü" hibrit veri yapısının bilimsel geçerliliğini desteklemektedir.
- **Majid Shahhosseini vd. (2019/2021) - *Coupling Machine Learning and Crop Modeling Improves Crop Yield Prediction in the US Corn Belt*:** ABD mısır kuşağındaki verimi tahmin etmek için Random Forest, LASSO, SVM ve XGBoost algoritmaları yarıştırılmıştır. İklim ve toprak gibi karmaşık tablo verilerinde XGBoost algoritmasının tüm diğer modelleri geride bıraktığı ve en düşük hata payıyla çalıştığı ispatlanmış olup, bu durum projemizdeki nihai model seçimimizi doğrudan doğrulamaktadır.
- **Michael Peichl ve ZALF Araştırma Enstitüsü Ekibi (2021) - *Machine Learning in Crop Yield Modelling*:** Almanya'da yürütülen bu projede 40 yıllık hava durumu ve toprak verileri kullanılarak rekolte tahmini yapılmıştır. Araştırmacılar, rekoltedeki değişkenliğin büyük kısmının meteorolojik faktörler ve toprak besin kapasitesiyle açıklanabileceğini Random Forest ile modellemiştir. Projede uygulanan "Özellik Seçimi" metodolojisi, bizim çalışmamızdaki Özellik Önemi (Feature Importance) analizimizle aynı teorik temele dayanır.
- **S. Kumar vd. (2020) - *Crop Yield Prediction Using Random Forest Algorithm and Decision Tree Classifiers*:** Toprak pH'ı, sıcaklık, nem ve yağış parametrelerinden oluşan veri setleri üzerinde Karar Ağaçları ve Rassal Orman algoritmalarının doğrusal olmayan karmaşık ilişkileri çözmedeki başarısı ve yüksek doğruluğu raporlanmıştır.

2.3. Literatürdeki Boşluk ve Projemizin Özgün Değeri

Literatür detaylıca incelendiğinde, projemizi mevcut akademik çalışmalardan ayıran ve sektöre

yenilik katan temel mühendislik farkları bulunmaktadır:

1. **Dijital İkiz (Digital Twin) Veri Mimarisi:** Mevcut çalışmaların büyük kısmı geçmişte kaydedilmiş statik, kapalı veri setleri (Kaggle vb.) üzerinden yürütülmektedir. Bizim projemizde ise, Open-Meteo REST API üzerinden çekilen 16 yıllık *gerçek* iklim verileri ile bitki fizyolojisi kurallarına uygun olarak Python ortamında simüle edilen *sentetik* sensör verileri dinamik bir şekilde birleştirilmiştir. Bu hibrit mimari, sistemin doğrudan gerçek dünya şartlarını taklit etmesini sağlamıştır.
2. **Doğa Gürültüsü (Noise Induction) ile Aşırı Öğrenmeyi Kırma:** Literatürdeki birçok modelin en büyük zafiyeti, laboratuvar şartlarındaki verileri ezberleyerek %95-99 gibi yapay olarak yüksek ve gerçek dışı doğruluk oranlarına ulaşmasıdır (Overfitting). Tarım, doğası gereği don, fırtına veya ani zararlı böcek istilası gibi beklenmedik riskler barındırır. Modelin ezber yapmasını önlemek ve bu belirsizlikleri simüle etmek için veri setine kasıtlı olarak **%15 oranında doğa gürültüsü** eklenmiştir. Modelimiz, %72.50 skoruyla doğadaki zorlukları tolere edebilen, çok daha güvenilir ve **sağlam (robust)** bir yapı sunarak literatürden ayrışmaktadır.
3. **Açıklanabilirlik ve Son Kullanıcı Entegrasyonu:** Birçok akademik araştırma sadece terminal ekranında biten kod bloklarından ibarettir. Projemiz ise yapay zekayı bir "kara kutu" olmaktan çıkararak *Özellik Önemi* analiziyle modelin kararlarını şeffaflaştırmış ve Streamlit framework'ü kullanılarak modeli son kullanıcının (çiftçinin) kullanabileceği interaktif bir "Karar Destek Web Uygulamasına" dönüştürmüştür.

3. Yöntemler

Bu bölümde, verilerin toplanması, analiz edilmesi, biyolojik kurallarla sentezlenmesi, ön işlemlerden (preprocessing) geçirilmesi ve model eğitim süreçlerinde izlenen metodolojik veri madenciliği adımları detaylı bir şeffaflıkla açıklanmaktadır.

3.1 Veri Seti

Projenin temelini oluşturan veri seti, 6000 satır (yaklaşık 16.5 yıllık sürekli günlük veri) ve bağımlı/bağımsız toplam 10 özellikten (feature) oluşan çok boyutlu bir yapıdır. Klasik makine öğrenmesi projelerinde hazır veri setleri kullanılırken, bu projede veri mimarisi sıfırdan ve hibrit

bir yaklaşımla inşa edilmiştir:

- **Meteorolojik İklimsel Veri Toplama:** Açık kaynaklı Open-Meteo REST API servisi kullanılarak İzmir'in tarımsal bölgelerini (Merkez Enlem: 38.4237, Boylam: 27.1428) yansıtacak şekilde 2006-2023 yılları arasındaki meteorolojik geçmiş taranmıştır. Günlük ortalama hava sıcaklığı (°C), metrekareye düşen günlük toplam yağış miktarı (mm) ve günlük güneşlenme süresi (saat) verileri JSON formatında çekilerek Pandas Dataframe'lerine ayrıştırılmıştır.
- **Tarımsal Kimya ve Sensör Simülasyonu:** Fiziksel donanım eksikliğini gidermek ve gerçekçi bir senaryo kurgulamak amacıyla Python NumPy kütüphanesinin olasılık fonksiyonları kullanılmıştır. Topraktaki bitki gelişiminden sorumlu olan makro besin elementleri (Azot - N, Fosfor - P, Potasyum - K) ile biyokimyasal reaksiyonları yöneten pH seviyesi ve Toprak Nemi yüzdeleri, bitki fizyolojisindeki ideal yetiştirme sınırlarına uygun istatistiksel dağılımlar (normal ve üniform dağılımlar) kullanılarak sentetik olarak üretilmiştir.

Tablo 1'de veri setini oluşturan değişkenler ve özellikleri özetlenmiştir.

Tablo 1. Özellik açıklamaları

Id	Özellik (Feature)	Veri Tipi	Açıklama
1	Azot (N), Fosfor (P), Potasyum (K)	Sayısal (Sürekli)	Topraktaki miligram/kilogram (mg/kg) cinsinden temel besin elementleri değerleri.
2	pH Seviyesi	Sayısal (Sürekli)	Toprağın asidite veya alkalinite seviyesini gösteren değer (Örn: 6.5).
3	Toprak Nemi	Sayısal (Sürekli)	Toprağın su doygunluk yüzdesi (%).
4	Sıcaklık, Yağış, Güneşlenme	Sayısal (Sürekli)	İzmir bölgesine ait gerçek meteorolojik

Id	Özellik (Feature)	Veri Tipi	Açıklama
			iklim ölçümleri (API).
5	Hasat Kalitesi	Kategorik (Hedef)	A (Premium), B (Standart) ve C (Düşük) kalite olmak üzere tahmin edilecek sınıf (Target).

Tablo 1'e göre, sistemimiz sadece tek tip bir veriye bağımlı kalmamış; toprağın kimyasal ve fiziksel özellikleri ile atmosferik koşulları entegre bir biçimde değerlendirerek çok boyutlu (multivariate) bir analiz zeminini sağlamıştır.

3.2 Veri Ön İşleme

Çeşitli kaynaklardan toplanan ham verilerin (raw data) makine öğrenmesi algoritmaları tarafından en verimli şekilde işlenebilmesi için aşağıdaki ön işleme (preprocessing) adımları uygulanmıştır:

- **Eksik Veri Doldurma (Mean Imputation):** API bağlantı hatalarından kaynaklanabilecek eksik veriler (Null/NaN), veri kaybını önlemek amacıyla ilgili sütunun aritmetik ortalaması (mean) ile doldurulmuştur.
- **Standardizasyon ve Ölçeklendirme (Feature Scaling):** Hava sıcaklığı (Örn: 25.5 °C) ile Azot miktarı (Örn: 120 mg/kg) gibi farklı ölçeklerdeki değişkenlerin model eğitiminde haksız ağırlık (bias) oluşturmasını engellemek için Scikit-learn kütüphanesinden StandardScaler uygulanmıştır. Bu yöntem, veriyi ortalaması 0, standart sapması 1 olacak şekilde dönüştürür.
- **Etiket Kodlama (Label Encoding):** Ağaç tabanlı modellerin matematiksel işlemleri yürütebilmesi için kategorik "Hasat Kalitesi" sınıfları (A, B, C), LabelEncoder aracılığıyla sayısal değerlere (0, 1, 2) dönüştürülmüştür.
- **Veri Bölme (Train-Test Split):** Modelin genelleme yeteneğini (generalization) ölçebilmek için veri seti %80 Eğitim (Train - 4800 örnek) ve %20 Test (Test - 1200 örnek) olarak bölünmüştür. Veri dağılımının dengesini korumak için stratify parametresi kullanılmıştır.
- **Hedef Değişken Belirleme ve Doğa Gürültüsü:** Kalite etiketleri belirli biyolojik kurallara

(NPK dengesi, optimum pH vb.) göre oluşturulduktan sonra, gerçek dünya koşullarındaki öngörülemez doğal afetleri (don, dolu vb.) simüle etmek için veri setinin **%15'lik rastgele bir bölümünün** etiketleri değiştirilmiş (Noise Induction) ve modelin aşırı öğrenmesi (Overfitting) engellenmiştir.

3.3 Değerlendirme Metrikleri

Sınıflandırma modellerinin performansını sayısal ve objektif olarak değerlendirebilmek için literatürde kabul gören temel metrikler (Accuracy, Precision, Recall ve F1-Score) kullanılmıştır. Karmaşıklık matrisi (Confusion Matrix) temel alınarak hesaplanan bu metriklerin formülleri aşağıda verilmiştir:

$$\text{Doğruluk (Accuracy)} = (TP + TN) / (TP + TN + FP + FN) \quad (1)$$

$$\text{Kesinlik (Precision)} = TP / (TP + FP) \quad (2)$$

$$\text{Duyarlılık (Recall)} = TP / (TP + FN) \quad (3)$$

$$\text{F1-Skoru} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall}) \quad (4)$$

Burada; **TP** (Gerçek Pozitif), **TN** (Gerçek Negatif), **FP** (Yanlış Pozitif) ve **FN** (Yanlış Negatif) değerlerini ifade etmektedir. Doğruluk (Accuracy) modelin genel olarak ne kadar doğru tahmin yaptığını gösterirken, Duyarlılık (Recall) özellikle tespiti zor olan azınlık sınıfların (A Kalite) ne oranda yakalanabildiğini ölçen en kritik metriktir. F1-Skoru ise Kesinlik ve Duyarlılığın harmonik ortalaması olup, dengesiz veri setlerinde (imbalanced data) modelin başarısını en net yansıtan göstergedir.

4. Makine Öğrenmesi Algoritmaları

Projede performansı maksimize etmek ve karşılaştırmalı teorik analiz yapabilmek amacıyla literatürde sınıflandırma (Classification) görevlerinin en popüler iki dev algoritması olan Random Forest ve XGBoost kullanılmıştır.

4.1 Random Forest (Rassal Orman) Eğitimi

Random Forest, temeli Karar Ağaçlarına (Decision Trees) dayanan ancak tek bir ağacın kolayca aşırı öğrenmeye (overfitting) düşme eğilimini kırmak için geliştirilmiş bir Topluluk Öğrenmesi (Ensemble Learning) yöntemidir. Çalışmamızda n_estimators=100 parametresi ile sistem, birbirinden bağımsız, her biri veri setinin rastgele alt örneklemleriyle (Bootstrap Sampling) beslenen 100 farklı karar ağacı oluşturmuştur.

Model tahmin yaparken, yeni bir sensör verisi sisteme girdiğinde, bu veri 100 farklı ağaçtan geçirilir ve her ağaç bağımsız bir tahmin üretir. Nihai karar, ağaçların "Çoğunluk Oylaması" (Majority Voting - Aggregation) sistemine göre verilir. Bu mimarinin (Bagging) projeye en büyük faydası, veri setimize kasıtlı eklediğimiz %15'lik gürültüye karşı doğal ve istatistiksel bir blokaj sağlamasıdır.

4.2 XGBoost (Extreme Gradient Boosting) Optimizasyonu

XGBoost, karar ağaçlarını paralel (bağımsız) değil, seri (ardışık) bir şekilde, birbirlerinin hatalarından ders alacak biçimde inşa eden çok güçlü bir Gradient Boosting algoritmasıdır. Her yeni oluşturulan ağaç, bir önceki ağacın doğru tahmin edemediği veri noktalarına (residual error) yoğunlaşır. XGBoost, sadece gradyan (1. türev) değil, aynı zamanda Hessian (2. türev) matrisini kullanarak Taylor fonksiyonu açılımı ile kayıp fonksiyonunu (Loss Function) minimuma indirir.

Projemizde XGBoost, modelin karmaşıklığını dizginlemek için learning_rate=0.1 (Öğrenme Hızı) ve max_depth=5 (Ağaç Derinliği) parametreleriyle konfigüre edilmiştir. Veri setimizde "A Kalite" ürünler sayıca en azınlıkta olan (Imbalanced Class) gruptu. XGBoost, az bulunan örnekleri bile zorla öğrenmeye çalışan agresif hata düzeltme mekanizması sayesinde azınlık sınıfların bulunmasında temel modelleri geride bırakmıştır.

5. Bulgular

Modellerin, eğitim sürecinde hiç maruz kalmadığı, tamamen izole edilmiş 1200 günlük bağımsız test seti üzerinde ürettiği sonuçlar karşılaştırmalı olarak değerlendirilmiştir.

Tablo 2'de makine öğrenimi modellerinin performansları temel metrikler üzerinden karşılaştırılmıştır.

Tablo 2. Makine Öğrenimi Modellerinin Performans Ölçütlerinin Karşılaştırması

Modeller	Doğruluk (Accuracy)	Kesinlik (Precision) (Makro)	Duyarlılık (Recall) (Makro)	F1 Skoru (Makro)
Random Forest (Baseline)	% 69.92	0.65	0.62	0.63
XGBoost (Ana Model)	**% 72.50**	**0.72**	**0.65**	**0.67**

Tablo 2 incelendiğinde, XGBoost modelinin hiperparametre optimizasyonu sayesinde test setindeki bütün performans ölçütlerinde Random Forest algoritmasını istikrarlı şekilde geride bıraktığı görülmektedir. Veri setine kasıtlı olarak eklenen %15'lik doğa gürültüsü nedeniyle hiçbir modelin maksimum tavan sınırı olan %85'i geçmesi matematiksel olarak beklenmemektedir. Bu bağlamda, %72.50'lik doğruluk oranı, modelin veriyi ezberlemeden (overfitting olmadan) temel tarımsal dinamikleri başarıyla öğrendiğini kanıtlayan optimal ve gerçekçi, **sağlam (robust)** bir skordur.

Özellikle, veri setindeki oranının nadirliği sebebiyle tespiti çok güç olan ve Dengesiz Veri (Imbalanced Data) problemi yaratan "A Kalite (Premium)" sınıf ürünlerin bulunma kapasitesini temsil eden **Recall (Duyarlılık)** değeri özel olarak incelendiğinde, bu değerin Random Forest'ta 0.32'de kalırken, XGBoost ile 0.37 bandına kadar çıkarılabildiği tespit edilmiştir. Bu ilerleme, ardışık hata öğrenme mekanizmasının doğrudan bir yansımasıdır.

5.1 Açıklanabilir Yapay Zeka (XAI) ve Özellik Önemi

Gelişmiş makine öğrenmesi modelleri genellikle "Kara Kutu (Black Box)" sistemleri olarak eleştirilir. Modelin kararlarını şeffaflaştırmak amacıyla XGBoost'un hesapladığı "Özellik Önemi (Feature Importance)" matrisi çıkarılmıştır. Modelin sınıflandırma yaparken eğitim sürecinde hangi değişkenleri en çok kullanarak bilgi kazancı sağladığı Şekil 1'in eşdeğeri olan verilerle şu şekilde listelenmiştir:

- **Topraktaki Azot (N) Seviyesi: %18 (0.18 Ağırlık) - En Yüksek Etki:** Azot, bitkilerde hücre duvarı ve protein sentezinin yapıtaşıdır. Yapay zeka, sadece sayısal desenleri tarayarak Azot'un hasat kalitesini etkileyen en dominant faktör olduğunu kendi matematiksel türetimleriyle keşfetmiştir.

- **Potasyum (K) Seviyesi: %15 (0.15 Ağırlık):** Bitkinin hastalıklara direnci ve meyve dolgunluğundan sorumlu olan Potasyum, karar almadaki ikinci temel direktir.
- **Fosfor (P) Seviyesi: %14 (0.14 Ağırlık):** Tohum oluşumu ve köklenmeyi sağlayan makro besin elementi.
- **Toprak pH Seviyesi: %13 (0.13 Ağırlık):** Azot ne kadar bol olursa olsun, toprak çok asidik veya çok bazik (alkali) ise kökler besinleri ememez. Model, pH'ın NPK emilimi üzerindeki çapraz bağlayıcı etkisini yansıtmıştır.
- **Günlük Hava Sıcaklığı (%12) ve Toprak Nemi (%12):** İklimsel ve topraksal su dengesi.
- **Günlük Güneşlenme Süresi: %9 (0.09 Ağırlık).**
- **Yağış Miktarı (mm): %4 (0.04 Ağırlık) - En Düşük Etki:** İzmir'in yazları kurak geçen karakteristik Akdeniz ikliminde ve modern tarımın genel olarak kontrollü damlama sulama üzerine kurulduğu varsayımında, doğal yağış miktarının rekolte kalitesini doğrudan değiştiren faktörler arasında en alt sıraya gerilemesi, yapay zekanın bölgesel iklimsel gerçekleri mükemmel bir şekilde modelediğinin kanıtıdır.

6. Sonuç, Tartışma ve Öneriler

Bu çalışmada geliştirilen Akıllı Tarım Karar Destek projesi, tablo verilerinde ve özellikle bitki fizyolojisi/iklim bilimi (agrometeorology) kombinasyonlarında, makine öğrenmesi algoritmalarının, özelliklede Boosting temelli ağaç mimarilerinin (XGBoost) ne kadar muazzam ve güvenilir bir kapasiteye sahip olduğunu teorik ve pratik olarak kanıtlamıştır. API destekli tarihsel hava durumu verisi ile istatistiksel sentetik sensör verilerinin bir dijital ikiz havuzunda buluşması ve üzerine kasten yerleştirilen %15 gürültü (noise) mühendisliği, sistemin dış dünyaya ve tarladaki anomalilere (robustness) son derece hazırlıklı olduğunu tescillemiştir.

Projenin çıktılarının somutlaştırılması amacıyla, eğitilen model bir Python backend'inden çıkarılarak **Streamlit framework'ü** aracılığıyla etkileşimli bir web paneline dönüştürülmüştür. Çiftçiler, sistemdeki kaydırma çubukları (sliders) ile gerçek zamanlı veri girişi yaparak saniyeler içinde "Anlık Kalite Tahmini" alabilmektedir. Bu entegrasyon, yapay zekanın laboratuvardan çıkıp doğrudan sahada uygulanabilirliğini göstermiştir.

Sınırlılıklar ve Karşılaşılan Zorluklar: Projenin temel zorluğu ve kısıtlaması, veri setindeki sınıf dengesizliği (Class Imbalance) olmuştur. A kalite (Premium) ürünlerin çok dar bir iklim/kimya

optimizasyonu bandında ortaya çıkabilmesi sebebiyle, verinin sadece %15'i A sınıfından oluşmaktadır. XGBoost'un hatalardan öğrenme kapasitesine rağmen, A kalite ürünlerin tespiti (Recall) %37 bandında kalarak sistemin geliştirilmesi gereken temel alanı oluşturmuştur.

Gelecek Çalışmalar İçin Öneriler: Gelecekte yapılacak projelerde veya ticari ürün fazlarında sistemin geliştirilmesi için üç ana hedef belirlenmiştir:

- **İleri Veri Dengeleme (Data Augmentation):** SMOTE (Synthetic Minority Over-sampling Technique) algoritması kullanılarak, çok boyutlu uzayda azınlık sınıfların (A kalite) en yakın komşu (K-NN) mantığıyla sentetik olarak matematiksel boyutta çoğaltılması ve modelin Recall (Duyarlılık) değerinin artırılması.
- **Gerçek IoT ve LoRaWAN Entegrasyonu:** Bilgisayar ortamındaki sentetik toprak değerlerinin yerini, doğrudan tarım arazilerine yerleştirilecek gerçek sensörlerden akan verilerin (Streaming Data) alması ve tahminlerin bulut ortamında dinamik olarak güncellenmesi.
- **Edge AI (Uç Bilişim) Entegrasyonu:** Sunucu bağımlılığını ortadan kaldırmak için, modellerin doğrudan akıllı otonom traktörlere veya sulama vanalarının üzerindeki mikrodenetleyicilere gömülmesi, veri gecikmesini sıfıra indirerek anlık müdahaleler (otonom gübreleme) sağlayacaktır.

Kaynaklar

---

[1] van Klompenburg, T., Kassahun, A., & Catal, C. (2020). Crop yield prediction using machine learning: A systematic literature review. *Computers and Electronics in Agriculture*, 177, 105709.

[2] Shahhosseini, M., Hu, G., & Archontoulis, S. V. (2020). Forecasting the magnitude and direction of corn yield response to nitrogen fertilizer using machine learning algorithms. *Agricultural and Forest Meteorology*, 292, 108107.

[3] Peichl, M., Thober, S., Meyer, V., & Marx, A. (2021). Machine learning in crop yield modelling: Identifying the most important meteorological and soil properties drivers. *Agricultural and Forest Meteorology*, 308, 108569.

[4] Kumar, S., et al. (2020). Crop Yield Prediction Using Random Forest Algorithm. *International Journal of Advanced Research in Computer Science*.

[5] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.

[6] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

[7] Streamlit Documentation (2024). The fastest way to build and share data apps. Retrieved from https://streamlit.io/

Ekler

Ek 1. Streamlit Web Uygulaması Kod Kesiti (app.py)

```
import streamlit as st
import pandas as pd
import joblib

st.set_page_config(page_title="Akıllı Tarım Yapay Zekası", page_icon="🌱", layout="centered")
st.title("🌱 Akıllı Tarım: Hasat Kalitesi Tahminleyici")

@st.cache_resource
def load_models():
    model = joblib.load('xgboost_tarim_modeli.pkl')
    scaler = joblib.load('tarim_scaler.pkl')
    le = joblib.load('label_encoder.pkl')
    return model, scaler, le

model, scaler, le = load_models()
# Arayüz ve tahmin mantığı devamı...
```